

Marcelo De la hoz Sierra CC 1037669479

Contexto de Aplicación

El contexto de aplicación se enfoca en la clasificación de vehículos a partir de imágenes. Este proyecto busca desarrollar un modelo de red neuronal convolucional (CNN) capaz de distinguir entre cuatro clases de vehículos: carros, buses, camiones y motocicletas.

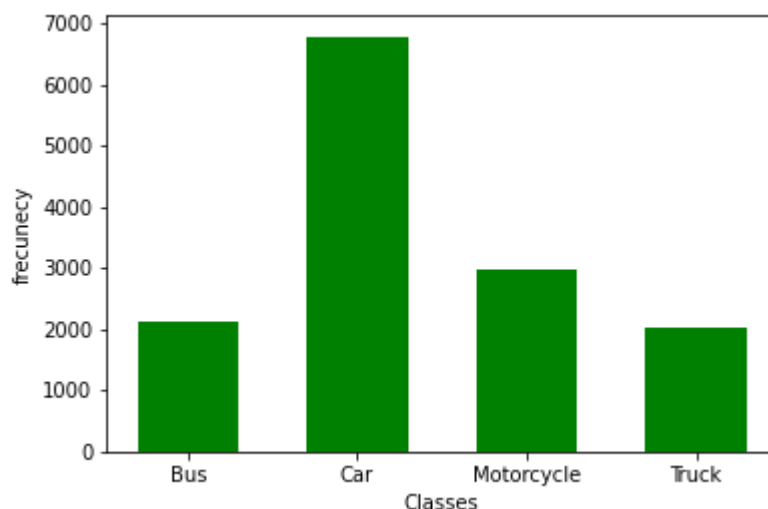
Objetivo de Machine Learning

El objetivo principal es predecir la clase a la que pertenece un vehículo en una imagen dada. Esto permitirá automatizar procesos de clasificación en diversas aplicaciones, como sistemas de monitoreo de tráfico y seguridad vial.

Dataset

El dataset que vamos a usar sera [TAU Vehicle Type Recognition Competition | Kaggle](https://www.kaggle.com/tauvote/tauvote) el cual contiene una gran cantidad de datos, en este caso imágenes de vehículos, distribuidas en 17 categorías de las cuales vamos a usar solo 4 (carros, buses, camiones y motos).

El total de imágenes del dataset es de 28045 imágenes para train y 7958 para test, pesando un total de 7.45 GB. de este se usarán 13933 imágenes que corresponden a las categorías seleccionadas. y están distribuidas de la siguiente forma:



Métricas de Desempeño

Métricas de Machine Learning:

- Accuracy (Precisión): Proporción de predicciones correctas respecto al total de predicciones.
- Loss (Pérdida): Indica la discrepancia entre las predicciones del modelo y las etiquetas reales.
- Matriz de Confusión: Permite visualizar el desempeño del modelo en cada clase y detectar posibles problemas de clasificación.

Métricas de Negocio:

- Tiempo de Inferencia: Medida del tiempo que el modelo tarda en realizar una predicción.

- Costo de Error por Clasificación Incorrecta: Evalúa el impacto económico de las predicciones incorrectas.
- Sensibilidad y Especificidad: Importantes en escenarios donde los costos de falsos positivos y falsos negativos son desiguales.

Referencias y Resultados Previos

Referencias Relevantes:

[TAU Vehicle Type Recognition Competition | Kaggle](#) Esta competición en Kaggle proporciona el dataset que estamos utilizando y puede contener kernels y soluciones anteriores que pueden servir como referencia.

Resultados Previos

- Hasta el momento, hemos entrenado un modelo de red neuronal convolucional (CNN) con la arquitectura personalizada. Esta arquitectura incluye varias capas convolucionales y de agrupación, así como capas de dropout y normalización por lotes para reducir el sobreajuste.
- Aunque el modelo ha demostrado la capacidad de aprender a partir de los datos, hemos observado que la curva de “Model Accuracy” no ha alcanzado los niveles deseados. Esto sugiere que el modelo podría estar teniendo dificultades para distinguir entre ciertas clases de vehículos.
- La curva de “Model Loss” también ha mostrado cierta desviación de lo ideal, indicando que las predicciones del modelo no se ajustan completamente a las etiquetas reales.
- Es importante reconocer que la arquitectura del modelo puede requerir ajustes adicionales, como la modificación de los hiperparámetros y la consideración de otras arquitecturas de CNN más avanzadas para lograr un mejor rendimiento en la clasificación de vehículos.

Plan Futuro:

- Dado que hemos utilizado una arquitectura de CNN personalizada, consideraremos la posibilidad de explorar arquitecturas pre-entrenadas como ResNet, Inception, o EfficientNet, que han demostrado un buen rendimiento en tareas de clasificación de imágenes.
- Realizaremos una búsqueda exhaustiva de hiperparámetros para encontrar la combinación óptima que mejore la precisión y reduzca la pérdida.
- Continuaremos experimentando con técnicas de aumento de datos y ajuste fino de modelos para mejorar la capacidad del modelo para generalizar a nuevas imágenes de vehículos.
- Seguiremos evaluando el desempeño del modelo utilizando las métricas de machine learning y negocio definidas anteriormente (accuracy, loss, tiempo de inferencia, costo de error por clasificación incorrecta, sensibilidad y especificidad).
- Mantendremos un enfoque en la optimización del modelo para lograr resultados más precisos y confiables en la clasificación de vehículos.

Estos ajustes y experimentos futuros deberían ayudarnos a abordar las limitaciones actuales y mejorar el rendimiento del modelo en la tarea de clasificación de vehículos a partir de imágenes.